

Célula Python analisada (índice 65)

```
# =====
# 20.1 Salvar Todos os Artefatos
# =====

print("=" * 70)
print("SALVAMENTO DE ARTEFATOS")
print("=" * 70)

import json

# Salvar resultados em JSON
results_summary = {
    'execution_date': datetime.now().strftime('%Y-%m-%d %H:%M:%S'),
    'dataset': {
        'total_records': len(df_clean),
        'train_records': len(train_df),
        'test_records': len(test_df),
        'n_features': len(feature_names),
        'test_season': '24/25',
    },
    'best_model': best_single_name,
    'best_model_metrics': optimized_results[best_single_name],
    'ensemble_metrics': ensemble_metrics,
    'ensemble_strategy': best_ensemble_strategy,
    'feature_importance_top10': global_imp.head(10).to_dict('records'),
}

results_path = str(PROJECT_ROOT / 'results' / 'results_summary.json')
save_json(results_summary, results_path)
print(f"📁 Resultados salvos em: {results_path}")

# Salvar feature names
save_json({'feature_names': feature_names}, str(PROJECT_ROOT / 'results' / 'feature_names.json'))

# Salvar modelos otimizados
for name, model in [('lgbm_optuna', lgbm_opt), ('catboost_optuna', cb_opt), ('xgboost_optuna', xgb_opt)]:
    model_path = str(MODELS_DIR / f'{name}.joblib')
    save_artifact(model, model_path)
    print(f"📁 Modelo {name} salvo em: {model_path}")

# Relatório final
elapsed_total = time.time() - EXECUTION_START
print(f"\n{'='*70}")
print(f"🎉 PROJETO CONCLUÍDO COM SUCESSO!")
print(f"\n{'='*70}")
print(f"\n⏱ Tempo total de execução: {elapsed_total/60:.1f} minutos")
print(f"\n📁 Artefatos salvos em:")
print(f"   📁 Modelos:    {MODELS_DIR}/")
print(f"   📁 Figuras:    {FIGURES_DIR}/")
```

```

print(f"  Resultados: {PROJECT_ROOT / 'results'}/")
print(f"  MLflow:      {MLRUNS_DIR}/")
print(f"\n  Resumo de Performance:")
print(f"  Melhor Modelo: {best_single_name}")
best_m = optimized_results[best_single_name]
print(f"  MAE:   {best_m['MAE']:.2f} dias")
print(f"  RMSE:  {best_m['RMSE']:.2f} dias")
print(f"  R²:    {best_m['R2']:.4f}")
print(f"\n  Ensemble ({best_ensemble_strategy}):")
print(f"  MAE:   {ensemble_metrics['MAE']:.2f} dias")
print(f"  RMSE:  {ensemble_metrics['RMSE']:.2f} dias")
print(f"  R²:    {ensemble_metrics['R2']:.4f}")
print(f"\n  20 melhorias metodológicas implementadas e validadas!")

```

Saída registrada da célula

=====

SALVAMENTO DE ARTEFATOS

=====

```

  Resultados salvos em: /home/andre/Downloads/injury_prediction_project/injury_prediction_advanced/results/results_sum
  Modelo lgbm_optuna salvo em: /home/andre/Downloads/injury_prediction_project/injury_prediction_advanced/models/lgbm
  Modelo catboost_optuna salvo em: /home/andre/Downloads/injury_prediction_project/injury_prediction_advanced/models/c
  Modelo xgboost_optuna salvo em: /home/andre/Downloads/injury_prediction_project/injury_prediction_advanced/models/xg

```

=====

PROJETO CONCLUÍDO COM SUCESSO!

=====

Tempo total de execução: 33.7 minutos

Artefatos salvos em:

```

  Modelos:   /home/andre/Downloads/injury_prediction_project/injury_prediction_advanced/models/
  Figuras:   /home/andre/Downloads/injury_prediction_project/injury_prediction_advanced/figures/
  Resultados: /home/andre/Downloads/injury_prediction_project/injury_prediction_advanced/results/
  MLflow:    /home/andre/Downloads/injury_prediction_project/injury_prediction_advanced/mlruns/

```

Resumo de Performance:

```

  Melhor Modelo: LightGBM_Optuna
  MAE:   8.59 dias
  RMSE:  14.59 dias
  R²:    0.9132

```

Ensemble (Blending):

```

  MAE:   8.56 dias
  RMSE:  14.55 dias
  R²:    0.9136

```

20 melhorias metodológicas implementadas e validadas!

Explicação detalhada

Esta célula realiza o fechamento do pipeline avançado de predição de lesões. Primeiro, ela cria o dicionário

results_summary com metadados da execução (data/hora), tamanho dos conjuntos de treino e teste, número de variáveis e temporada avaliada. Em seguida, grava esse resumo em JSON no diretório results e salva também a lista de variáveis em feature_names.json. Depois, persiste os três modelos otimizados com Optuna (LightGBM, CatBoost e XGBoost) em arquivos .joblib no diretório models, garantindo reprodutibilidade para uso futuro em inferência. Por fim, imprime um relatório consolidado com tempo total, caminhos de artefatos e métricas finais de desempenho.

Nos resultados desta execução, o melhor modelo individual foi o LightGBM_Optuna, com MAE de 8.59 dias, RMSE de 14.59 dias e R^2 de 0.9132, indicando alta capacidade de explicação da variabilidade do alvo. O ensemble por Blending apresentou leve melhora, com MAE de 8.56 dias, RMSE de 14.55 dias e R^2 de 0.9136. A melhoria é pequena, porém consistente, sugerindo ganho marginal de generalização ao combinar modelos. O pipeline também reporta 33.7 minutos de execução e confirma a implementação e validação de 20 melhorias metodológicas, com geração completa dos artefatos para auditoria e reuso.